



Dokumentace projektu z kursu Strojové učení a rozpoznávání
**Detektor jedné osoby z obrázku obličeje
a hlasové nahrávky**

Brno, 4. května 2026

David Kvaček
xkvace00@stud.fit.vutbr.cz

Úvod

Tento projekt implementuje detektor jedné osoby na základě obrázků obličeje a hlasových nahrávek. Systém se skládá ze tří nezávislých klasifikátorů: audio, obrazového a multimodálního. Implementace je v jazyce Python s využitím knihoven `numpy`, `librosa`, `scikit-image` a `scikit-learn`.

V rámci projektu jsou použita pouze poskytnutá data z adresářů `target_train`, `target_dev`, `non_target_train` a `non_target_dev`.

Cílem projektu je navrhnout systémy schopné generalizace na neznámá data při použití velmi omezeného množství trénovacích dat. Klíčovými aspekty je řešení problémů s generalizací a omezením přetrénování (overfittingu). Zvláštní pozornost je věnována výběru validační strategie, která respektuje strukturu dat podle nahrávacích sezení.

Datová sada a předzpracování

Soubory v datových sadách mají formát `f401.01_f21_i0.0.png` nebo `...wav`, kde první pole identifikuje osobu a druhé pole nahrávací sezení. Tato informace je zásadní pro návrh validační strategie, protože seřazené vzory ze stejného sezení mohou mít podobné podmínky záznamu. Proto je během vývoje důležité zabránit tomu, aby se stejná sezení objevila současně v trénovacích i validačních datech.

Předzpracování zahrnuje:

- audio: detekce aktivních segmentů řeči pomocí Voice Activity Detection (VAD), normalizace hlasitosti, výpočet MFCC a jejich první a druhé derivace pro zachycení dynamiky signálu,
- obraz: převod do odstínů šedi, standardizace velikosti a částečná úprava geometrie obrazu, aby bylo možné pracovat se srovnatelnými příznaky i při malé variabilitě trénovacích vzorků,
- multimodální zpracování: vytvoření kompatibilních pravděpodobnostních skóre z audio i obrazového systému pro pozdní fúzi.

Veškeré augmentace jsou aplikovány pouze na trénovací data, aby byla zachována integrita validačních kroků. Tím se minimalizuje riziko nepřímého úniku informací z validačních vzorů do procesu učení.

Navržené systémy

Navržený systém obsahuje tři samostatné komponenty: audio detektor, obrazový detektor a multimodální fúzi. Každá komponenta je postavena na jednoduchém, ale odolném přístupu, který lze dobře ověřit v podmínkách omezených dat.

Audio systém

Audio systém využívá MFCC (Mel-frequency cepstral coefficients) příznaky jako hlavní reprezentaci řeči. Kromě základních MFCC jsou použity i jejich první a druhé časové derivace, což umožňuje zachytit dynamiku hlasu a změny intonace, které mohou být u cílové osoby konzistentní napříč záznamy. VAD (Voice Activity Detection) odstraňuje tiché části záznamu, aby se model soustředil na skutečnou řeč. Základní model je SVM s RBF jádrem ($C = 10.0$) s vyváženými vahami tříd a pravděpodobnostními odhady. Tento přístup je zvolen kvůli omezenému množství dat a omezenému riziku přetrénování.

Obrazový systém

Obrazový systém pracuje s detekovanými obličejovými snímky ve formátu PNG. Obrázky jsou převedeny na odstíny šedi a normalizovány do jednotného rozměru, aby se redukoval vliv rozdílných velikostí a kontrastu. Pro extrakci příznaků je použit HOG (Histogram of Oriented Gradients), který zachycuje směr a intenzitu hran typických pro obličejové struktury. Tento typ příznaků je vhodný pro omezené datové sady, protože nevyžaduje trénování složitých neuronových sítí. Augmentace obrazů zahrnuje rotaci o $\pm 5^\circ$ a drobné geometrické posuny, aby systém lépe toleroval mírné změny pozice hlavy a orientace obličeje. Model je opět SVM s RBF jádrem ($C = 1.0$) s vyváženými vahami tříd a pravděpodobnostními odhady.

Multimodální systém

Multimodální systém kombinuje audio a obrazový detektor na úrovni skóre, tedy pozdní fúze. Pro každý vstupní vzor jsou získána pravděpodobnostní skóre jednotlivých modelů, které jsou následně zprůměrovány. Tento přístup je zvolen proto, že jsou systémy nezávislé a jejich společné skóre poskytuje lepší celkové rozhodnutí.

Validační strategie

Vzhledem k omezenému množství a struktuře dat (seskupení podle nahrávacích sezení) je použita křížová validace Leave-One-Session-Out. Tato strategie zajišťuje, že modely se netrénují na datech ze stejného sezení jako validační množina. Tím se simuluje reálná situace, kdy by evaluační data mohla pocházet z jiného nahrávacího prostředí než tréninková data. Křížová validace je aplikována na všechna dostupná trénovací data z adresářů `target_train`, `target_dev`, `non_target_train` a `non_target_dev`. Díky tomu lze efektivně využít celý soubor dat pro učení a zároveň získat odhad generalizační chyby pro různá sezení.

Řešení generalizace a přetrénování

Poskytnutá trénovací data jsou velmi omezená, což zvyšuje riziko přetrénování. Evaluační data mohou obsahovat neznámé charakteristiky jako šum, změny kvality obrazu, odlišnou hlasitost nebo různé formy deformace. Pro řešení těchto problémů jsou aplikovány následující techniky:

- **augmentace dat:** audio augmentace zahrnuje přidání šumu, náhodné zrychlení a zpomalení řeči, a práci s časovou osou pro simulaci různých nahrávacích podmínek, obrazová augmentace zahrnuje rotace o $\pm 5^\circ$, drobné posuny a normalizaci kontrastu, augmentace se aplikuje pouze na trénovací data, aby validační výsledky zůstaly nezávislé,
- **volba modelu:** SVM s RBF jádrem je zvolen místo složitějších modelů, protože nabízí dobrou kompenzaci mezi velikostí a rizikem přetrénování při omezených datech, použití vyvážených vah tříd pomáhá kompenzovat nerovnováhu mezi cílovými a necílovými příklady, pravděpodobnostní odhady umožňují kombinaci modalit a jemnější nastavení rozhodovacího prahu,
- **standardizace a regularizace:** příznaky jsou v každém validačním souboru standardizovány samostatně, to zabraňuje úniku informací z validačních dat do trénovacího procesu, parametry jsou nastavovány obezřetně, aby se předešlo přetrénování na malé množině dat.

Zpracování evaluačních dat

Evaluační data jsou určena pouze k automatickému zpracování a nesmí být použita k poslechu či vizuální kontrole jednotlivých vzorů. Pro běh nad evaluačními daty stačí spustit skripty se stejnými parametry jako během vývoje. Jedinou nezbytnou podmínkou je přítomnost vybraných složek s trénovacími či evaluačními daty, např. `non_target_dev`, `target_train`, `eval`, ve stejném adresáři jako samotné zdrojové soubory (`audio.py`, `image.py`, `multi.py`). Výsledné soubory s příponou `.txt` obsahují výsledky v požadovaném formátu.

Postup získání výsledků

- **Požadavky:** Python 3.7+, knihovny `numpy`, `librosa`, `scikit-image`, `scikit-learn`, datové adresáře `target_train`, `target_dev`, `non_target_train`, `non_target_dev`, `eval`.
- **Instalace:** `pip install numpy librosa scikit-image scikit-learn`.
- **Spuštění systémů:**
 1. audio systém: `python audio.py` (výsledky v `audio.txt`),
 2. obrazový systém: `python image.py` (výsledky v `image.txt`),
 3. multimodální systém: `python multi.py` (výsledky v `multi.txt`).
- **Formát výsledků:** každý řádek obsahuje název souboru, skóre, tvrdé rozhodnutí, přičemž skóre udává jistotu systému, tvrdé rozhodnutí je binární (1 pro cílovou osobu při ≥ 0.5).