

Dokumentace projektu z kursu Ukládání a příprava dat
**Projekt, 3. část: příprava dat a jejich popisná
charakteristika**

Brno, 11. prosince 2025

Martin Burian (xburiam00@stud.fit.vutbr.cz)

Karel Kaska (xkaska02@stud.fit.vutbr.cz)


David Kvaček (xkvace00@stud.fit.vutbr.cz)

Charakteristika datové sady a atributů

Analyzovaná datová sada obsahuje záznamy o inzerátech ojetých i nových osobních automobilů, získaných z portálu <https://www.otomoto.pl>. Sada ve svém surovém stavu obsahuje 174 záznamů. Každý záznam reprezentuje jednu nabídku vozu a je definován následujícími atributy:

- **URL** (kategorický typ) – unikátní odkaz na inzerát, slouží jako identifikátor,
- **Název** (kategorický typ) – plný název vozu, často obsahující i motorizaci a výbavu,
- **Cena** (numerický typ) – cena vozu v lokální měně (*PLN*), hodnoty vyžadují předzpracování (odstranění mezer), rozsah je široký, od levných ojetin po luxusní vozy,
- **Značka** (kategorický typ) – výrobce vozu (např. *BMW*, *Audi*, *Volkswagen*), v sadě se vyskytuje cca 25 unikátních značek,
- **Model** (kategorický typ) – konkrétní model vozu (např. *Golf*, *A4*, *X1*),
- **Barva** (kategorický typ) – dominantní barva vozu (např. *černá*, *šedá*, *bílá*),
- **Počet dveří** (numerický typ) – nejčastěji nabývá hodnoty 5,
- **Počet sedadel** (numerický typ) – typicky 5, vyskytují se i 4 (kupé) nebo 7 (SUV), tento atribut obsahuje chybějící hodnoty,
- **Rok výroby** (numerický typ) – rozsah let v analyzovaném vzorku je v rozmezí 1995 až 2025.

Analýza rozložení hodnot



Obrázek 1: Histogram a krabicový graf atributu cena vozu.


Z histogramu cen (obrázek 1 vlevo) je patrné, že rozložení je silně zešikmené doprava. Většina nabízených vozů se pohybuje v nižších cenových hladinách (do 50 000 až 100 000). S rostoucí cenou četnost inzerátů klesá. Na pravém chvostu grafu lze pozorovat několik málo inzerátů s extrémně vysokou cenou, což reprezentuje luxusní segment.

Krabicový graf (obrázek 1 vpravo) jasně ilustruje větší počet hodnot spektra, které se nacházejí nad hranicí třetího kvartilu ($Q3$) než pod hranicí prvního kvartilu ($Q1$). Tyto hodnoty reprezentují záznamy o vozech, jejichž cena násobně převyšuje medián celého souboru.




Obrázek 2: Bodový graf vztahu mezi atributy rok výroby a cena.

Bodový graf (obrázek 2) zobrazuje vztah mezi stářím vozu a jeho cenou. Je zde viditelná pozitivní korelace. Starší vozy (před rokem 2010) se drží převážně v nízkém cenovém pásmu s minimálním rozptylem. U vozů vyrobených po roce 2020 si lze všimnout nejen výrazně vyšší ceny, ale také obrovský rozptyl cen, který je dán rozdíly mezi značkami a výbavou u nových aut.



Obrázek 3: Krabicový graf atributu cena pro 15 vybraných značek vozů.


Tento graf (obrázek 3) porovnává cenové hladiny u vybraných značek. Premiové značky jako např. *BYD* či *Cupra* mají výrazně vyšší medián ceny. Naopak vozy značek *Volkswagen*, *Škoda*, *Ford* nebo *Toyota* mají širší mezikvartilové rozpětí (*IQR*) než masové značky jako *Opel* a *Renault*. U značek *Volkswagen* či *Ford* lze pozorovat velké rozpětí hodnot od třetího kvartilu (*Q3*) směrem k hranici $Q3 + 1.5 * IQR$, což může být způsobeno prodejem nových modelů (např. rok 2025) vedle starých ojetin.



Obrázek 4: Teplotní mapa průměrné ceny vozu dle atributů značka a barva.

Barevná mapa (obrázek 4) zobrazující, jak kombinace značky a barvy vozu ovlivňuje průměrnou cenu. Mapa odhaluje zajímavé anomálie. Obecně platí, že u prémiových značek jsou tzv. business barvy (*černá, šedá*) asociovány s vyšší průměrnou cenou. Nicméně extrémní hodnoty mohou vznikat u specifických kombinací, kde malý počet vzorků zkreslí průměr. V rámci běžných značek (např. *Hyundai, Kia*) je vliv barvy na cenu zanedbatelný a mapa je barevně jednotnější.

Histogram na obrázku 5 ukazuje strukturu nabízeného vozového parku na základě konkrétního atributu rok výroby. Podle očekávání vykazuje graf levostranné zešíkvení (směrem k novějším rokům), jelikož v datasetu je vysoké zastoupení zánovních vozů včetně mnoha modelů s rokem výroby 2025 (např. *BYD Seal, Cupra Terramar*). Starší vozy s rokem výroby 2010 a dříve tvoří chvost distribuce.



Obrázek 5: Histogram distribuce vozů podle roku výroby.

Detekce odlehlých hodnot

K detekci odlehlých hodnot je primárně využita metoda mezikvartilového rozpětí (IQR). Hodnota je považována za odlehlou, pokud leží pod $Q1 - 1.5 * IQR$ nebo nad $Q3 + 1.5 * IQR$. Doplnkově je provedena detekce odlehlých hodnot pomocí metody standardního skóre (tzv. Z -skóre) a její upravené podoby. Různé přístupy identifikují odlišný počet odlehlých hodnot, přičemž upravená metoda Z -skóre se jeví jako robustnější.

V rámci atributu cena je detekována řada odlehlých hodnot na horní hranici spektra. Příkladem může být *Land Rover Defender* (cca 460 000), *Lexus LM* (cca 450 000) nebo *Audi Q7* (cca 410 000). Nejedná se však o chyby v datech, nýbrž o validní záznamy luxusních nebo zcela nových vozů v datasetu, které se výrazně liší od průměrné ojetiny.

Co se týče atributu rok výroby, zde lze uvést příklad *BMW Serie 3* z roku 1995. V kontextu převážně moderních vozů (2010+) působí rok 1995 jako odlehlá hodnota, ale opět jde o validní data.

Analýza chybějících hodnot


Při kontrole integrity dat vychází, že většina atributů (cena, značka, model, barva, rok výroby) je vyplněna u veškerých záznamů. Atribut počet sedadel obsahuje prázdné hodnoty (NaN), tj. *BMW X1* (rok výroby 2010), *Opel Astra* (rok výroby 2017), *Renault Captur* (rok výroby 2018) a několik dalších.

Chybějící hodnoty nejsou systematické pro jednu značku, ale vyskytují se náhodně napříč celou datovou sadou. Vzhledem k tomu, že počet chybějících hodnot je malý (přesněji řečeno jich je 12, tj. u 6.9 % záznamů), je možné tyto záznamy pro účely modelování buď odstranit, nebo doplnit nejčastější hodnotou (modus), což je v drtivé většině případů hodnota 5.

Korelační analýza

Na základě vztahů numerických atributů je provedena korelační analýza. Tato analýza slouží k měření a vizualizaci lineárního vztahu mezi v tomto případě více numerickými atributy v datové sadě. Zde se numerickými atributy myslí cena, rok výroby, počet dveří a počet sedadel. Pro kvantifikaci vztahů je použit Pearsonův korelační koeficient (r), jehož hodnota se pohybuje v intervalu $[-1, 1]$, kde:

- $r = 1$ značí dokonalou pozitivní korelaci, tj. s růstem hodnoty jednoho atributu roste i hodnota druhého atributu,
- $r = -1$ značí dokonalou negativní korelaci, tj. s růstem hodnoty jednoho atributu klesá hodnota druhého atributu,
- $r \approx 0$ značí absenci lineárního vztahu.



Obrázek 6: Korelační matice numerických atributů.

Z korelační matice (obrázek 6) plyne, že např. mezi cenou a počtem dveří vozu není v podstatě žádný lineární vztah a tudíž tyto dva atributy nevykazují žádné známky vzájemné korelace. Na druhé straně největší pozitivní korelace si lze všimnout u atributů cena a rok výroby, z čehož lze usoudit, že čím je hodnota atributu rok výroby vyšší (tzn. analyzovaný vůz je novější), tím roste logicky i jeho cena. V rámci ostatních dvojic atributů lze pozorovat korelační koeficient v rozsahu 0.19 až 0.39, tj. slabá pozitivní korelace.

Příprava datové sady

Cílem této fáze je transformace původních dat do podoby vhodné pro konkrétní dolovací algoritmus, tj. predikce ceny vozu. Na základě charakteru dat jsou vytvořeny dvě odlišné varianty datové sady. Jedna je určená pro algoritmy pracující s kategorickými daty a druhá pro algoritmy vyžadující numerický vstup.

Odstranění irelevantních atributů

Z datové sady jsou odstraněny atributy URL a název u všech záznamů. Atribut URL slouží pouze jako identifikátor a pro modelování nemá prediktivní hodnotu. Atribut název obsahuje příliš specifické informace (vysoká kardinalita), které jsou již částečně obsaženy v attributech značka a model.

Ošetření chybějících hodnot

V datové sadě jsou identifikovány chybějící hodnoty jen a pouze u numerického atributu počet sedadel. Pro splnění zadání jsou uvažovány následující dvě metody:

1. **Odstranění záznamů** – tato metoda by vedla ke ztrátě přibližně 7 % dat, vzhledem k malé velikosti datasetu (méně než 200 záznamů) je tato metoda vyhodnocena jako nevhodná pro finální sady.
2. **Imputace (doplnění hodnot)** – zvolená metoda pro obě finální varianty, u numerických atributů (v tomto případě pouze počet sedadel) jsou chybějící hodnoty nahrazeny mediánem, který je robustnější vůči odlehlým hodnotám než průměr, zatímco u kategorických atributů by byly případné chybějící hodnoty nahrazeny modusem (nejčastější hodnotou).

Ošetření odlehlých hodnot

Na základě analýzy v předchozí části jsou detekovány odlehlé hodnoty v attributech cena a rok výroby vozu. Pro čištění dat je použita metoda mezikvartilového rozpětí (*IQR*). Záznamy, jejichž hodnota leží mimo interval $[Q1 - 1.5 * IQR, Q3 + 1.5 * IQR]$, jsou z datasetu odstraněny. Tímto krokem jsou eliminovány extrémní cenové výkyvy (luxusní vozy) a historická vozidla, což přispěje k lepší generalizaci modelů.

Varianta datové sady pro kategorické vstupy

Tato varianta je připravena pro algoritmy vyžadující diskretní vstupy. Numerické atributy jsou diskretizovány do intervalů nebo převedeny na textové řetězce. Hodnoty atributu cena jsou diskretizovány do čtyř kategorií: *levné* (do 50 000), *střední* (do 100 000), *drahé* (do 200 000) a *luxusní* (nad 200 000). Obdobně je provedena diskretizace pro atribut rok výroby do kategorií *velmi nové* (do 3 let), *nové*

(3–7 let), *střední* (7–15 let) a *staré* (nad 15 let). Hodnoty atributů počet dveří a počet sedadel jsou převedeny na kategorické atributy (např. hodnota 5 převedena na řetězec *5_doors*). Výsledná sada obsahuje pouze kategorické atributy: *brand*, *model*, *color*, *doors_cat*, *seats_cat*, *age_cat*, *price_cat*.

Varianta datové sady pro numerické vstupy

Tato varianta je určena pro metody založené na matematických výpočtech. Kategorické atributy jsou transformovány na čísla a následně je rovněž provedena jejich normalizace. Atributy značka a model (s vysokým počtem unikátních hodnot) jsou převedeny pomocí *Label Encodingu* (přiřazení celého čísla každé unikátní hodnotě). Atribut barva (nízký počet unikátních hodnot) je převeden pomocí *One-Hot Encodingu* (vytvoření binárního sloupce pro každou barvu), aby se předešlo zavedení umělého uspořádání mezi barvami.

Všechny numerické atributy (včetně nově vzniklých z kódování) jsou normalizovány a škálovány do intervalu $[0, 1]$ pomocí metody *Min-Max Scaling*. Tento krok zajišťuje, že atributy s vysokými hodnotami (např. cena) nebudou dominovat nad atributy s nízkými hodnotami (např. počet dveří) při matematických výpočtech.

Závěr a zhodnocení

V rámci třetí části projektu je provedena explorativní analýza a následná příprava datové sady inzerátů jednotlivých automobilů. Analýza potvrzuje očekávané závislosti, zejména silnou korelaci mezi rokem výroby a cenou, a odhaluje specifika datasetu, jako je přítomnost luxusních vozů tvořících odlehle hodnoty. Proces přípravy dat úspěšně transformuje surová data do podoby vhodné pro strojové zpracování.

Klíčovým krokem je vyřešení chybějících hodnot metodou imputace a odstranění extrémů, což zvyšuje robustnost dat. Vytvořením dvou variant datasetu je dosaženo univerzálnosti pro další fáze dobývání znalostí. Výsledné datové sady jsou konzistentní, zbavené šumu a připravené k okamžitému použití v dolovacích úlohách.